小组任务单：项目范围与可验证需求

软件理论与工程 · 研一 · 第三次课 · 2026年10月9日 · 每组一份

> **任务：**讨论项目首版范围，选择一个需求，写出可由另一组执行的验收条件，记录人工核查与互评修订。
> **提交：**保存填写后的HTML，或打印填写后提交；文件命名“组号_需求编号_v2”。具体渠道与截止时间由教师宣布。今晚不要求代码、完整架构或模型实测。

本页状态：AI Agent 修订版：单个批改 Agent＋工具调用＋有限修正＋教师复核。已填写需求设计与验收方案；组号、成员、人工核查、互评及实际评分待补填。产品及 Agent 尚未实现，合成样本不是模型实测。

建议节奏：35分钟讨论与分析，10分钟互评修订。填写过程中请及时点击保存；关闭页面前保存最终版本。下载后可自行重命名。

基本信息

组号与项目名称

组号：9
项目名称：面向课程的 AI Agent 作业辅助批改系统

成员与本次分工

按实际人数说明：范围讨论、验收质询、记录与核查，可兼任。

成员姓名及实际人数：杨峥、刘韫恺、王艺臻、张呦呦、胡梦杰；5
范围讨论负责人：杨峥、刘韫恺；核对教师困难、单 Agent 目标、授权范围和排除项。
验收质询与人工核查负责人：王艺臻、张呦呦；逐项核对量表、合成样本、分数计算、工具调用摘要、修正轮次及失败处理。
记录与版本负责人：胡梦杰；保存任务单，填写真实 AI 核查结论、互评处理及 Agent 需求修订记录。

日期、版本与评价人

日期：2026年10月9日
当前版本：v1 草案
评价人：杨峥

一、项目范围讨论

用户与一个核心困难

谁在什么情况下遇到什么困难？不要只列功能。

用户：教授课程的教师，课程助教可在教师授权下辅助复核。
场景：教师收到任务单，需要按 A—F 六个维度逐份评分并给出修改意见。
核心困难：逐份对照量表、查找证据、判断档位、核算分数并检查草稿错误耗时；教师若还要反复提示 AI 查找依据和改错，辅助作用有限。
拟解决的问题：教师给定单份批改目标后，由批改 Agent 自主组织六维分析、调度核查工具、处理可修正错误，并把证据和待核查事项集中交给教师。
最终判断：Agent 生成建议，教师复核确认评分与理由。

首版学习主线

从用户开始操作，到获得有用结果，写出连续步骤。

1. 教师进入单份作业批改页面，选定本课固定量表。
2. 教师粘贴已去除直接身份信息的任务单文本，点击“生成评分草稿”，授权批改 Agent 处理当前这一份作业。
3. Agent 创建当前任务的六维分析清单，调用量表读取工具取得规则，按各维内容需要调用原文定位工具，形成档位建议与理由。
4. Agent 调用计分工具和草稿校验工具；根据返回的错误决定补查证据、修改相关维度或重新计分，最多进行 2 轮修正。
5. 校验通过后，教师查看六维草稿、证据定位、待核查事项和可展开的执行摘要；未通过则查看失败原因，选择重试或人工批改。
6. 教师逐项采纳或调整建议档位与理由；系统按量表重算分项得分和总分。
7. 教师确认后得到可保存的批改记录；生成阶段的状态始终为草稿／待复核，不自动发布正式成绩。
模型或工具失败时，保留当前输入和量表版本，由教师决定是否重新启动任务。

本次做什么、暂时不做什么

明确首版范围及容易扩张但决定排除的内容。

首版做什么：一个基于大语言模型的批改 AI Agent，面向一名教师的一份匿名文本作业，使用固定 A—F 量表；自主组织六维分析，调用量表、原文定位、精确计分及草稿校验工具，根据反馈有限修正，再交教师确认。
Agent 的目标：形成完整、证据可追溯、计算正确的六维评分草稿；具体查证顺序与错误修正操作由 Agent 在当前任务范围内决定。
授权边界：只能访问本次作业及指定量表，工具只用于读取、定位、计算和校验；正式成绩确认与发布权限不交给 Agent。
本次只展开 FR-01；交付填写后的需求任务单和测试方案，尚未实现产品、运行批改 Agent 或实测模型效果。
暂不做：批量导入、PDF/OCR、自由创建量表、跨课程评分、学情统计、出题、课堂问答、自动排名、教学平台成绩发布、模型训练及多智能体协作。

需求依据与功能状态

记录平台观察、任务要求或教师评价规则。标明：已观察／拟新增／待确认。

已观察／已核对：用户提供的 HTML 与 PDF 是同一份任务单，要求明确范围、选择一条需求，给出三类场景、验收方法、质量约束及人工／互评记录。
已观察／已核对：配套量表 A—F 满分为 15、20、30、15、10、10；档位系数为 100%、70%、30%，相关内容缺失为 0；先找证据再选档，允许半分，合计满分 100。
已确认的用户要求：教学辅助功能须涉及 AI Agent；因此将原先未明确 Agent 机制的评分流程细化为单 Agent 的目标、工具调用、校验反馈和有限修正闭环。
拟新增：批改 Agent、四类工具、当前任务的执行摘要、最多 2 轮错误修正和教师接管流程；这是待开发功能，不是已上线能力。
待确认：教师实际困难、匿名化要求、合成样本预期档位、Agent 草稿是否适用于正式教学场景。由范围负责人联系教师，姓名待补填。
数字来源：评分规则来自参考资料。

二、选择一条需求

需求编号与名称

例如 FR-01：针对理解缺漏的追问。

需求编号：FR-01。
需求名称：批改 AI Agent 生成并校验可追溯的作业评分草稿。
关联用户：课程教师。
关联依据： A—F 六维量表及用户明确提出的 AI Agent 要求。
Agent 数量：1 个；四类工具属于普通程序／服务，不作为其他智能体。
首版仅展开此一条需求，质量约束及教师复核作为其关联条件。

用户故事

作为……，我需要……，以便……。

作为课程教师，我需要把单份匿名作业的批改目标交给一个 AI Agent，让它按固定量表自行查找证据、提出六维建议、调用工具计算并校验、根据反馈修正可修正错误，再交我复核，以便减少重复查找与核算，并为学生提供有依据的改进反馈。

功能需求

在……条件下，用户……，系统应……。写前提、动作和可观察结果。

前提：教师提供非空的单份匿名任务单文本并指定量表；模型及所需工具可用。
触发：教师点击“生成评分草稿”，启动一个批改 Agent 任务，目标为完成当前作业的 A—F 六维评分草稿。
Agent 行为：建立六维分析清单，调用量表读取工具获取规则；按内容需要调用原文定位工具，提出档位与理由；调用精确计分工具及草稿校验工具，依据反馈决定补查证据、修正相关维度或重算分数。
修正与停止：首次草稿必须校验；校验未通过时最多进行 2 轮修正，每轮修正后再次校验，即每个任务最多 3 次草稿校验。校验通过即停止生成并交教师复核；达到上限仍失败则停止任务、列出原因，转教师处理，不继续无限调用。

成功输出：六维名称、满分、建议档位、分项得分、证据字段／段落及原文、简短理由、待核查标记、总分和量表版本。显示“评分草稿，待教师确认”，并提供任务执行摘要，包括工具调用结果、校验结论和修正轮次。
计算与证据：档位使用 100%、70%、30%，整体缺失为 0；分项＝满分×系数，总分精确相加。非缺失项引用须能逐字定位；缺失项写“该部分未提供”；歧义和前后矛盾须标为待人工核查。
失败输出：模型／工具报错时停止当前任务；持续校验失败时不展示为有效完整草稿。两者均保留原作业和量表版本，提供失败原因、重试及人工批改入口；不产生新的有效评分或正式成绩。
教师控制：教师可复核、调整档位与理由，再由计分工具重算并明确确认；Agent 没有正式成绩发布权限。

三、验收场景

T1 正常场景

输入或前提：
用户操作：
预期结果：
通过／不通过的具体判据：

输入或前提：使用 f14 的完整匿名合成样本 S1 和正常的模型／四类工具。S1 是供 Agent 批改的学生作业样例，其中的身份与协作经过均为合成数据。
用户操作：邻组验收人以教师角色粘贴 S1 正文，点击“生成评分草稿”，随后展开任务执行摘要。
预期结果：显示 A—F 六维；档位均为 100%；得分依次为 15、20、30、15、10、10，总分 100；量表版本正确，每维证据可在 S1 定位，状态为“评分草稿，待教师确认”。
Agent 判据：执行摘要显示已建立六维分析清单，实际调用量表读取、原文定位、精确计分和草稿校验工具；最终校验通过，修正轮次未超过 2。摘要可映射到本次输入与量表版本，不能只有“Agent 已完成”的空泛描述。
通过／不通过判据：评分、证据、版本、状态及上述工具调用全部符合预期才通过；漏维、虚构引用、未调用所需工具、未校验或未经教师确认形成正式成绩，均不通过。
预期档位是按参考量表拟定的答案，执行前须由教师或邻组核定；目前未运行该产品或进行模型实测。

T2 差异或边界场景

改变的输入、角色或规则：
用户操作：
预期结果及变化理由：
通过／不通过的具体判据：

改变的输入：从 S1 构造 S2，仅清空【C 区开始】与【C 区结束】之间的全部正文，保留其余文本与量表。清空内容包括三类验收场景、判定人、步骤、样本与阈值。
用户操作：粘贴 S2，启动同一批改 Agent，查看评分和原文定位结果。
预期结果：Agent 对 C 的证据定位得到“该部分未提供”，C 档位为缺失（0）、得分 0；其他维度保持 A=15、B=20、D=15、E=10、F=10，总分 70，状态仍为待教师确认的草稿。
变化理由：缺失为 0 来自参考量表；其余五维原文未变，不能因为缺失 C 而无依据改变其他分项。D 的行为规则不替代 C 的三类验收场景。
通过／不通过判据：结果为 C=0、总分=70，未引用已删除文字；任务摘要能追溯到 S2 与同一量表，并显示校验通过。虚构 C 证据、缺失项非零或无依据改变其他分项均不通过。
数字来源：评分规则来自参考资料；S2 删除规则为团队拟定边界测试。

T3 异常场景

如何模拟异常：
用户操作：
预期提示、数据保留与恢复方式：
通过／不通过的具体判据：

T3a 工具服务失败：使用 S1，清除先前草稿，在受控环境使原文定位工具首次返回 HTTP 503。启动 Agent，预期明确提示失败、所失败工具及“原作业和量表已保留”，不产生新的有效评分；恢复工具后由教师点击重试，无需再粘贴，结果符合 T1。
T3b 可修正的引用错误：使用正常服务和 S1，在首次模型草稿中仅把 B 维证据替换为“【不存在的证据 QX-001】”，其他信息不变。草稿校验应返回 B 维引用不存在；Agent 依据反馈重新定位 B 原文、修正引用并再次校验。预期经 1 轮修正后通过，得分和总分仍符合 T1。执行摘要须有首次失败、B 维补查证据及再次通过，错误草稿不能作为有效结果展示。
T3c 持续校验失败：对首次及两轮修正后的草稿持续注入同一 B 维错误引用。预期最多发生 2 轮修正、3 次草稿校验，随后停止，提示“草稿校验未通过，请教师核查”，保留原输入和量表，提供重试或人工批改入口；没有有效完整草稿或正式成绩，也不进行第 3 轮修正。
共同操作与判据：分别执行上述故障注入，检查输入前后逐字一致、工具调用摘要、校验次数、修正轮次、失败状态与人工入口。每个子场景的全部要求均满足才通过；输入丢失、虚构证据被接纳、越过上限、失败仍产生成绩或无法恢复，均不通过。
异常模拟、QX-001 标记和修正次数是团队拟定验收条件；这里仅定义方案，未实际运行批改 Agent。

谁来验、怎样验、用多少样本、什么算通过

判定人：
验收步骤与证据保存方式：
固定样本及正确结果的来源：
样本规模与通过阈值：
数字来源：团队承诺／引用出处。

判定人：邻组验收人（组号、姓名待补填）执行；本组核查角色（姓名待补填）核对工具调用、证据及分数；量表与预期档位有争议时由教师裁定。
验收前：人工核定 S1 的预期档位，冻结输入、量表版本和参考结果；工具校验与人工评价不可用 AI 自己的输出作正确答案。
步骤：用 S1 执行 T1；仅删除 C 区正文构造 S2 执行 T2；依次注入工具 503、首次错误引用、持续错误引用，分别执行 T3a、T3b、T3c；逐项对照各场景所有判据。
证据保存：按“场景／子场景_第几次”保存输入、量表版本、输出截图／文本、六维得分及通过记录；另保存与本任务标识关联的执行摘要，包括工具名、输入版本、调用结果、校验错误、修正轮次和停止状态。T3 还保存故障配置与失败前后输入比对。
样本用途：下面 S1 是待批改的学生作业合成样例，其内容描述课堂统计项目；批改系统的 Agent 行为由本任务单 f10、f16、f17 及任务执行摘要定义。S1 内部的模拟 AI／互评记录不属于本组真实经历。
参考结果：按参考量表和 S1 明示内容，S1 预期 15+20+30+15+10+10=100，S2 预期 15+20+0+15+10+10=70；T3b 修正后的有效草稿与 S1 相同；T3a 失败阶段、T3c 停止阶段没有新的有效评分。
样本规模与阈值：2 份文本变体、3 种受控异常；T1、T2、T3a、T3b、T3c 各执行 3 次，共 15 次，15/15 次均满足全部判据才通过。当前执行状态为未执行。
数字来源：满分、系数及缺失为 0 来自参考资料；每场景 3 次、总计 15 次、15/15 阈值、最多 2 轮修正／3 次校验均为团队拟定值，尚未实测，不是泛化效果承诺。

S1 的预期证据锚点（仍需核查完整内容）：
A：“逐一识别按时、逾期和未提交的学生”；配合依据、功能状态与排除项。
B：“FR-S01：统计小测提交情况”；配合前提、点击动作和可见输出。
C：“每场景执行 3 次，共 9 次”；配合三类输入、判据、判定人及数字来源。
D：“提交时间小于或等于截止时间为按时”；配合变化理由、失败与人工核查。
E：“匿名角色乙采纳，因为”；配合模拟问题、建议、拒绝理由与具体修改。
F：“三类人数之和应等于名单人数”；配合模拟原文反馈、修订、版本与角色责任。

可直接复用的 S1 正文如下（粘贴时只取此范围，不粘贴上面的参考结果）：
【S1 开始：匿名合成任务单，仅供系统验收】
基本信息：合成组 G-S1；项目“课堂小测提交情况统计”；版本 v2。
成员及分工：匿名角色甲负责范围和记录，匿名角色乙负责验收质询及规则核查；匿名评价人丙负责互评。以上身份和下述协作经过均为合成测试数据。

A 用户、依据与范围
用户是课程教师。教师在小测截止后，需要从多条提交记录中逐一识别按时、逾期和未提交的学生，人工计数易重复且缺少可复核明细。
依据：本合成案例的教学规则规定，每个学生以截止后统计时已收到的最后一条有效提交记录为准，提交时间等于截止时间算按时。该规则是测试样例设定，不是声称真实课程已有此政策。
已观察：仅核对本测试样例中的名单与记录；未声称观察到真实教学平台。拟新增：单次小测的三类人数及学生明细。待确认：真实课程是否采用最后一次提交规则，由教师确认。
用户主线：教师选择一次小测，导入匿名名单与提交记录，核对截止时间，点击统计，查看三类人数与明细，人工确认。
首版做单次统计与明细核查；暂不做排名、自动催交、正式成绩发布和跨班比较。

B 需求表达
FR-S01：统计小测提交情况。
作为课程教师，我需要查看本次小测的按时、逾期和未提交人数及对应学生明细，以便核查提交情况并安排补交。
在教师已提供一份无重复学生编号的名单、有效提交记录及截止时间的条件下，教师点击“统计”，系统应按该学生最后一条有效提交记录分类，显示三类人数与学生编号；三类人数之和应等于名单人数。

【C 区开始】
C 验收场景与方法
T1 正常：名单 S01、S02、S03；截止 2026-10-09 21:00；收到 S01 于 20:58、S02 于 21:05 的有效提交，S03 无提交。教师点击统计。预期按时 1、逾期 1、未提交 1；明细分别为 S01、S02、S03；人数合计 3。人数与明细均相符才通过。
T2 边界：在同一输入中把 S01 的最后提交时间改为 21:00，其余不变。教师重新统计。预期 S01 仍为按时，三类人数仍为 1、1、1，因为时间等于截止时间算按时。若 S01 被列为逾期则不通过。
T3 异常：把 S02 的学生编号置空，其他输入不变。教师点击统计。预期指出第 2 条提交记录缺少学生编号，保留原始输入并暂停生成本次统计；补回 S02 后重新统计可得到 T1 结果。出现错误分类、丢失输入或无法恢复均不通过。
判定人：匿名评价人丙执行，匿名角色乙核查。步骤：依次输入 T1、T2、T3，保存原始输入、输出截图和逐项判定记录；异常修复后再核对一次。
固定样本就是上述 3 名匿名学生和 2 条记录，正确结果按本样例明示的时间分类规则逐条计算；不是外部统计

数据或模型实测。
每场景执行 3 次，共 9 次；9 次均满足各项判据才通过。3 名学生、3 次重复和 9/9 阈值均为本合成测试案例的团队拟定值。
【C 区结束】

D 行为依据与边界
输入包括匿名名单、学生编号、提交时间和截止时间；名单有重复编号时须先提示修正。
规则：未收到有效提交为未提交；最后有效提交时间小于或等于截止时间为按时，大于截止时间为逾期。名单外编号的记录不纳入人数并提示教师核查；采用明确规则计算，不使用 AI 判断类别。
输出每个学生的类别和计算所用时间，汇总三个类别的数量。修改某学生最后有效提交时间后，仅其分类及相关类别人数按规则变化；修改截止时间后按新截止时间重新计算全班。
质量约束：统计请求失败时，当前页面的名单、记录与截止时间逐字保留。普通笔记本桌面浏览器中模拟服务失败，执行前后分别复制三个输入逐字比对，须全部一致；100% 保留是团队拟定目标，尚未实测。
提交记录缺编号或时间无法解析时，提示对应记录并暂停结果生成；由教师修正后重试。测试规则应用于真实课程前，由教师核查政策是否一致。

E AI 协作与人工判断（本段为模拟测试记录）
工具与日期：模拟需求审查 AI，2026-10-09；不是实际调用日志。
模拟提交问题：若学生恰好在截止时刻提交，如何避免验收歧义？
模拟建议摘要：明确提交时间等于截止时间的归类。
模拟人工判断：匿名角色乙采纳，因为“截止前提交”无法判定等于截止时间的情况；拒绝 AI 同时建议的“自动排名”，因为超出单次提交情况统计范围。
模拟具体修改：将“截止前算按时”改为“最后有效提交时间小于或等于截止时间算按时”，并增加 T2 的 21:00 边界输入。

F 互评修订与交接（本段为模拟测试记录）
模拟互评人：合成邻组 G-P、匿名评价人丙。
模拟引用原文：“显示提交人数”。问题：不能判断是否重复计数或遗漏名单学生。
模拟修改建议：补充三类人数、学生明细和人数合计校验。
模拟处理：匿名角色甲采纳，因为明确输出可以逐项核对；修改为“三类人数之和应等于名单人数”，并在 T1 写明 1、1、1 和合计 3。
模拟版本：v1 为上述旧表述，v2 为当前文本；甲保存版本，乙检查边界和异常条件，丙按固定样本复验。待确认的真实课程规则由教师负责。
【S1 结束】

四、质量约束与行为依据

至少一项相关质量约束

例如响应时间、记录保存或权限约束。
指标：
测量起止点或检查步骤：
设备／网络／数据条件：
通过标准与数字来源：

NFR-01 数据保留：关联 FR-01。Agent 因工具错误或持续校验失败而停止时，当前页面原作业与量表版本逐字保留率为 100%，由教师决定重试或人工批改。
检查步骤：在 T3a 和 T3c 每次执行前后复制原作业与量表版本逐字比对，检查失败时无新有效评分；恢复服务／撤销注入后，用保留输入重试。
NFR-02 有限执行：首次草稿后最多 2 轮修正、最多 3 次草稿校验。通过后立即交教师复核；持续失败到上限后停止，不继续调用下一轮生成或校验。
检查步骤：按 T3c 的工具调用摘要计数，核对首次校验与两轮修正、各自结论及最终状态；按 T3b 检查一次修正通过后停止。
设备／网络／数据：普通笔记本桌面浏览器、同一页面保持打开，使用 S1 与固定量表；正常网络下通过受控工具／模型输出注入模拟故障，再解除注入，避免未知网络波动影响判断。
通过标准：相关场景各重复 3 次，全部满足保留、有限执行与恢复条件。保留范围是当前页面的任务失败与重试流程。
数字来源：100% 保留、2 轮修正、3 次校验及每场景 3 次均为团队拟定目标，未进行产品或模型实测。

输入、判断依据与输出的关系

输入：
依据或规则：
判断与输出：
相关输入或规则改变后，应如何响应：
失败时如何处理、何时需要人工核查：

输入：一份匿名作业、固定量表版本和教师本次批改授权。作业中的“请给满分”等内容属于待评价数据，不能改变 Agent 的量表、工具权限或教师确认要求。
Agent 目标与状态：完成可复核的六维草稿；在当前任务中保留输入版本、量表版本、六维分析清单、工具结果、校验错误及修正轮次。根据内容需要和工具反馈决定下一步查证或修正。
四类工具及职责：量表读取工具返回 A—F 规则和权重；原文定位工具从本次作业返回真实摘录、字段／段落和位置，或明确未提供；精确计分工具根据权重与档位计算分项和总分；草稿校验工具核对六维完整性、档位合法性、引用与原文一致、分数计算和草稿状态，并返回可操作的错误项。
依据：A=15、B=20、C=30、D=15、E=10、F=10；档位系数为 100%、70%、30%，相关内容整体缺失为 0。分项＝满分×系数，总分精确相加；A 的 70% 为 10.5、30% 为 4.5，保留半分。
闭环：Agent 先组织分析并取证，生成草稿；校验失败则按错误项补查原文、改正相关建议或重算分数，修正后再校验。最多 2 轮修正；通过交教师，持续失败则停止并转人工。工具报错直接报告失败，由教师决定重试。
输入改变：删除 S1 的 C 区后，定位工具报告缺失，C=0、总分=70，其余证据未变；恢复内容后重新建立当前输入的证据，不能沿用旧版本引用。教师调整档位后，计分工具重算分项与总分。
人工核查：内容矛盾、档位解释有争议或部分缺项须标明具体问题；零散缺项不能一律按整体缺失判 0。结构

校验通过也不等于语义评分已获教师认可，教师须核对原文与档位后确认。
输出与权限：只生成草稿、证据、理由、执行摘要及待核查事项；Agent 不跨作业访问资料，不修改原作业、不发布成绩，普通工具不作为其他智能体。

多智能体交接（仅选多智能体功能时填写）

角色与职责：
各角色输入和输出：
交接数据：
某个角色失败时的处理与人工控制：

架构：1 个批改 AI Agent＋四类普通工具＋教师复核；本栏补充单 Agent 的工具与人工交接，不涉及多个智能体之间的交接。
角色与职责：教师给定目标、作业及量表，复核最终草稿；批改 Agent 自主组织六维分析、选择查证步骤、调用工具并按反馈修正；工具分别执行量表读取、原文定位、精确计分及草稿校验。
输入和输出：教师→Agent 为匿名作业、输入版本、量表版本及批改授权；Agent→工具为当前任务标识和相应读取／定位／计分／校验参数；工具→Agent 为规则、真实引用、分数或错误项；Agent→教师为完整草稿或停止原因、待核查事项及执行摘要。
交接数据：任务标识、原文版本、量表版本、六维建议、引用位置与原文、分项和总分、工具调用结果、修正轮次、校验状态；全程与当前作业关联，防止引用旧输入。
失败与人工控制：工具报错保留输入并停止；校验未通过最多修正 2 轮，仍失败则转教师。教师可以检查原因、重试或人工批改；最终评分须由教师确认。
边界：四类工具不各自承担自主目标，也不标为独立 Agent；首版没有多智能体分工或通信协议。

五、AI协作与人工核查

审查记录

工具与日期：
提交给AI的问题：
一条建议摘要：
人采纳／拒绝及理由：
具体修改：
若工具不可用，说明原因并记录人工质询及修改。

工具与日期：Codex，2026年10月9日；用于读取资料、整理需求与本次 Agent 修订。
真实问题：最初要求“根据参考资料完成给出的html”；本次进一步提出“功能是否涉及ai agent,若没有则做对应修改”。
建议摘要：原稿涉及 AI 评分但未明确 Agent 目标、工具调度和反馈修正；本次改为单个批改 Agent，配置四类普通工具、最多 2 轮修正及教师复核。
可核实的人类选择：用户已选择作业辅助批改、覆盖六维、真实记录待补填，并授权按本次 Agent 要求修改；这是方向及修改授权，不代表逐项人工核查已完成。
具体修改：f5/f10 补充 Agent 流程与停止条件，f13 增加错误引用修正及持续失败，f14 同步为 15 次验收，f15 补充有限执行约束，f16/f17 明确工具和交接。
人工采纳／拒绝及理由：方向与修改授权如上；对修正上限、工具职责、样本预期和每条判据的真实核查结论仍待本组核查负责人填写。

六、互评与修订

邻组反馈

互评组号／评价人：
引用原文的问题：
为什么影响验收：
具体修改建议：

本组处理与最终版本

采纳或拒绝及理由：
修改前→修改后：
最终版本：
仍待确认的事项与负责人：

当前版本：v1 草案。
本次实际修订依据：用户进一步要求涉及 AI Agent。
本次修改前→修改后：原“单一分析流程生成六维草稿”→“单个批改 Agent 自主组织分析、调用四类工具、按校验反馈最多修正 2 轮并交教师”；原 T3 只有服务报错→增加引用错误修正、持续失败停止，验收从 9 次同步为 15 次。
以上是本次需求修订，不是邻组互评记录；邻组反馈采纳／拒绝、理由及互评修改前后仍待真实互评补填。
正式最终版本：待核查与互评处理完成后，由记录负责人确定并保存。
待确认与责任：记录负责人补齐身份／分工；范围负责人确认教师需求和授权边界；核查负责人核定 S1/S2、工具摘要、修正次数及失败

七、评分与反馈记录

维度评分及原文证据

评价方式：自评／互评／教师
A 用户、依据与范围：__/15；证据：
B 需求表达：__/20；证据：
C 验收可执行性：__/30；证据：
D 行为依据与边界：__/15；证据：
E AI协作与人工判断：__/10；证据：
F 互评修订与交接：__/10；证据：
总分：__/100

评价方式：待实际评价人选择自评／互评／教师；本栏只列候选原文证据，尚未真实评分。
A 用户、依据与范围：待评价/15；证据 f4 教师反复查证和改错的困难，f6 单 Agent 目标与权限边界，f7 来源／功能状态。
B 需求表达：待评价/20；证据 f8 FR-01、f9 用户故事、f10 授权触发、工具调用、校验修正与可见输出。
C 验收可执行性：待评价/30；证据 f11 正常、f12 缺失边界、f13 三类异常子场景，f14 固定样本、执行摘要、判定角色与 15/15 阈值；真实验收人及参考结果核定仍待补齐。
D 行为依据与边界：待评价/15；证据 f15 数据保留与有限执行，f16 量表、工具反馈及停止条件，f17 单 Agent 的工具／教师交接。
E AI 协作与人工判断：待评价/10；证据 f18 本次真实问题、建议、方向确认与实际修订；逐项人工核查及对应

理由仍待填写。
F 互评修订与交接：待评价/10；证据 f2 角色责任、f20 本次版本与 Agent 修订；真实邻组反馈和处理记录待完成，不能按已有互评记分。
总分：待评价/100；评价人先找原文证据再按参考量表选档、相加。
注意：S1=100 与 S2=70 是合成验收样本的预期评分，15/15 是拟定验收阈值，都不是本任务单的实际成绩或模型实测结论。

优先改进与下一步

最需要修改的一项：
具体改法：
负责人：

最需完善：补齐真实核查与互评，确认单 Agent 的工具调用、修正上限和人工控制均可执行。
具体改法：补组号、成员与分工；由核查负责人逐项核对量表和 S1/S2，检查 T3a 工具失败、T3b 一轮修正、T3c 上限停止的判据，记录至少一条实际采纳／拒绝理由与改动；再请邻组引用原文提意见、本组记录处理。
负责人：记录负责人统筹、核查负责人复核、范围负责人确认教师授权与边界；姓名待补填，允许兼任。
下一步：补身份责任 → 核定样本与 Agent 判据 → 互评修订 → 实际评价与最终版本 → 保存 HTML。
当前交付为需求分析，产品实现、模型效果验证及 Agent 工具运行尚未开展。

提交前自检：

☑ 范围明确　☑ 只选一条需求　☑ 三类验收场景齐全　☑ 数字来源明确
☑ 行为有判断依据　☑ 有人工核查记录　☐ 有互评处理及版本

配套评价量表（练习前阅读）

练习开始前公布。本量表用于自评、互评和教师形成性反馈，评价今晚要求的分析成果，不评价未要求提交的代码、完整架构或模型实测效果。

维度	满分	清楚可执行：100%	基本成立：70%	尚不清楚：30%
A 用户、依据与范围	15	用户困难与功能对应；来源、现状与排除项清楚	用户功能明确，来源或边界有一项缺失	仅列功能／愿望，混淆现状与建议
B 需求表达	20	编号、前提、动作、可见结果齐全且一致	主体结果明确，前提或动作有歧义	仅写智能、方便、快或技术方案
C 验收可执行性	30	至少三场景覆盖正常、差异／边界、异常；输入、预期、判据、判定人、样本、数字来源齐全	三场景多数可判定，但关键字段或数字来源缺失	只有正常流程或无法复核的效果承诺
D 行为依据与边界	15	输入／规则与输出可追溯，变化有理由；普通功能边界或AI失败与人工核查明确	解释部分依据边界，但关键变化或失败结果未说明	输出变化无依据或异常与需求无关
E AI协作与人工判断	10	有问题、建议、采纳／拒绝理由与具体修改；不可用时有人工审查替代记录	有记录，决策理由或改动对应不完整	仅写AI生成／未用，没有审查
F 互评修订与交接	10	有版本、成员责任、带证据的反馈与对应修订／合理拒绝	有反馈修订，缺版本、责任或处理理由	无法追踪反馈和改动

评分：各维度选一档，得分＝满分×档位系数；缺失相关内容为0。允许半分，六维相加满分100。先找文本证据再选档。

课堂诊断分不自动等同课程总评分；正式计入方式按课程要求确定。分享机会不影响得分。维度对应模板：1—3→A，4→B，5—6→C，7→D，8→E，9与版本责任→F。